GLOBAL SOLUTION 2026.2 · APRENDIZADO PROFUNDO COM REDES NEURAIS CONVOLUCIONAIS

Segurança pública inteligente em São Paulo

Classificação de ocorrências como furto ou roubo com uma rede neural MLP

Objetivo: treinar e comparar redes MLP que classificam uma ocorrência já registrada como furto ou roubo e integrar a melhor a um site para testar novos exemplos. A rede não prevê crimes futuros.

339.923
boletins únicos de furto e roubo (SSP-SP, 2025)

3
arquiteturas de MLP comparadas

1
aplicação web para testar exemplos

Lucas Mota · RM 566670 · Trabalho individual · FIAP

Problema e base de dados

Ocorrências já registradas na capital paulista: o modelo classifica o tipo do registro, não prevê crimes futuros

Fonte e recorte

- SSP-SP, SPDadosCriminais 2025 (ssp.sp.gov.br/estatistica/consultas)
- Município do fato: São Paulo (capital); fatos de 2025
- Classes: FURTO - OUTROS (0) e ROUBO - OUTROS (1)
- 339.923 boletins únicos (delegacia + ano + número)

15.000 registros na amostra estratificada (semente 42)

28% / 72% roubos e furtos (4.204 e 10.796): classes desbalanceadas

Atributos escolhidos e o que os dados mostram no treino

Bairro

Onde. Os 35 mais frequentes; os demais viram OUTROS.

Tipo de local

Onde. Via pública tem 32,9% de roubo; terminais, residências e outros, de 6% a 12%.

Período do dia

Quando. Sem informação em 57% dos registros, que concentram 89% dos roubos.

Dia da semana

Quando. De 25,6% a 30,1% de roubo em todos os dias: quase não separa as classes.

Preparação dos dados

As regras foram definidas só com o treino, para o teste não influenciar o modelo

1

Limpeza

Filtro por município do fato, natureza e ano. BOs únicos por delegacia + ano + número; 68 boletins com rótulos contraditórios removidos.

2

Atributos

Quatro categóricos: bairro, período, tipo de local e dia da semana. Ausentes viram NAO INFORMADO; categorias raras viram OUTROS.

3

Codificação

One-hot ajustado só no treino: 65 entradas binárias (0 ou 1). Sem escalonamento, pois não há variáveis numéricas.

4

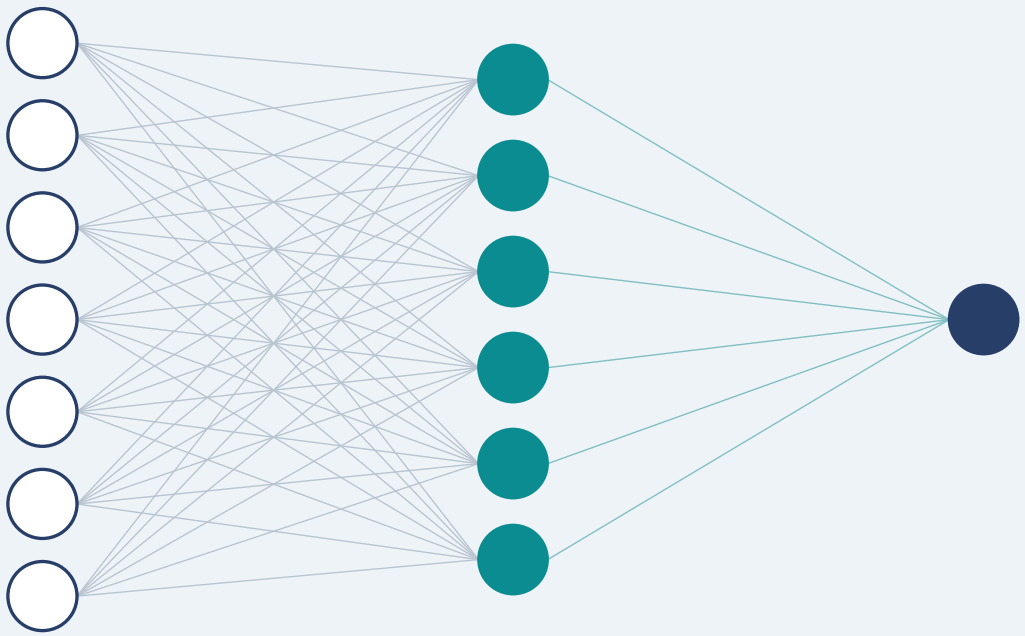
Separação

Divisão estratificada em 70%, 15% e 15%: treino 10.500, validação 2.250 e teste 2.250, com a mesma proporção de roubos.

Sem vazamento de dados: a natureza da ocorrência, o número do BO e a delegacia não entram como entrada da rede, e o conjunto de teste só é usado na avaliação final.

Arquitetura da MLP escolhida

Rede A: 65 entradas, uma camada oculta de 16 neurônios com ReLU e uma saída com sigmoid



Desenho simplificado: a rede real tem 65 entradas e 16 neurônios ocultos.

Como a rede funciona

1. Entrada: cada atributo vira colunas com 0 ou 1 (one-hot).
2. Camada oculta: cada neurônio soma entrada × peso + bias, e a ReLU zera os valores negativos.
3. Saída: a sigmoid transforma o resultado em uma probabilidade de roubo, de 0 a 1.
4. Decisão: roubo se a probabilidade for maior ou igual ao limiar de 0,34.

Total: 1.073 parâmetros treináveis (65×16+16 na camada oculta e 16×1+1 na saída).

Configuração do treinamento

Os mesmos hiperparâmetros nas três redes: só a arquitetura muda

Função de perda

Binary cross-entropy

Mede o erro de uma probabilidade em um problema de duas classes; combina com a saída sigmoid.

Otimizador

Adam, taxa 0,001

Ajusta os pesos de forma adaptativa, com uma taxa de aprendizado pequena e estável.

Épocas

Até 25

EarlyStopping (paciência 4) para quando a perda de validação não melhora e restaura os melhores pesos. A rede A parou na época 13 e voltou à 9.

Batch size

64 exemplos

Os pesos são atualizados a cada 64 exemplos, ou seja, 165 passos por época.

Ativações

ReLU e sigmoid

ReLU nas camadas ocultas; sigmoid na saída, que dá a probabilidade de roubo.

Reprodutibilidade

Semente 42

Mesma amostra, divisão e inicialização em toda execução: os números se repetem.

Três arquiteturas e o que mudou

Variamos camadas, neurônios e regularização, e o resultado quase não mudou

Rede A

Ponto de partida simples

- Dense 16 · ReLU
- Dense 1 · sigmoid

Perda de validação 0,4920 · recall 29,79%

Rede B

Mais capacidade de aprendizado

- Dense 32 · ReLU
- Dense 16 · ReLU
- Dense 1 · sigmoid

Perda de validação 0,4907 · recall 7,13%

Rede C

Rede maior com regularização

- Dense 64 · ReLU
- Dropout 0,25
- Dense 32 · ReLU
- Dense 1 · sigmoid

Perda de validação 0,4898 · recall 15,37%

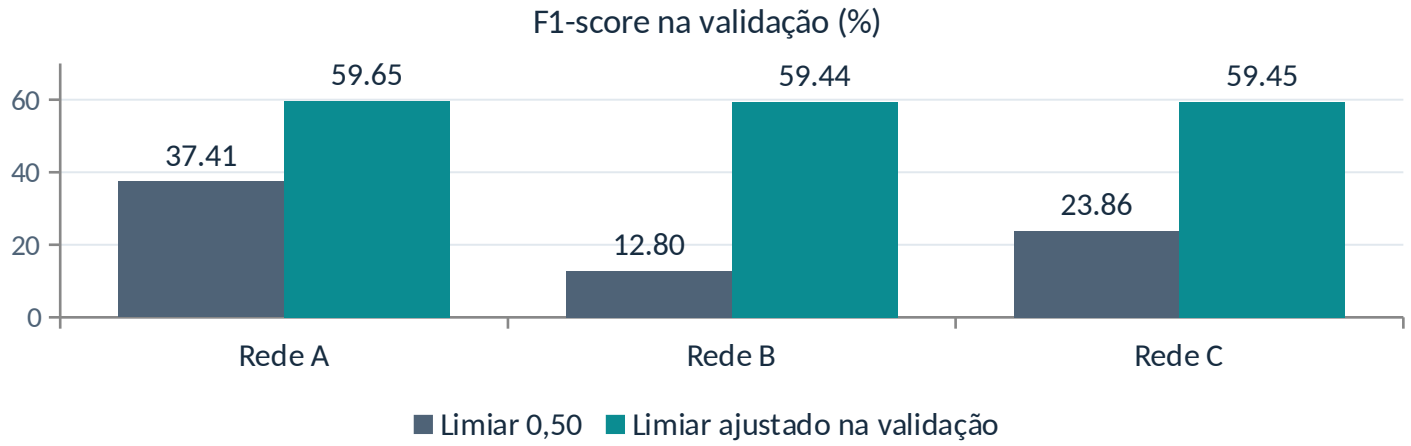
Mais camadas, neurônios ou Dropout quase não mudaram a perda: o limite está nos atributos, não na rede.

Comparação e escolha do modelo

Seleção feita só na validação; o teste ficou intocado até a avaliação final

Modelo	Acurácia	Precision	Recall	F1	Perda
Rede A (escolhida)	**72,04%**	**50,27%**	**29,79%**	**37,41%**	**0,4920**
Rede B	72,76%	62,50%	7,13%	12,80%	0,4907
Rede C	72,49%	53,30%	15,37%	23,86%	0,4898
Sempre "furto"	*71,96%*	*0,00%*	*0,00%*	*0,00%*	—

Validação, limiar 0,5, roubo como classe positiva; Perda = perda de validação.



Escolha: rede A

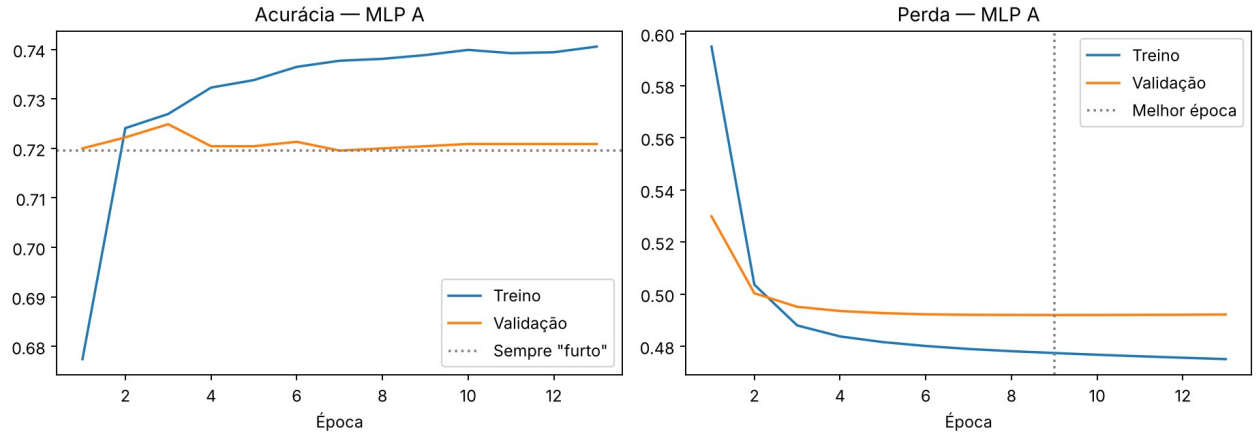
Maior F1-score na validação com o limiar padrão de 0,5 (37,41%). O teste não participou da decisão.

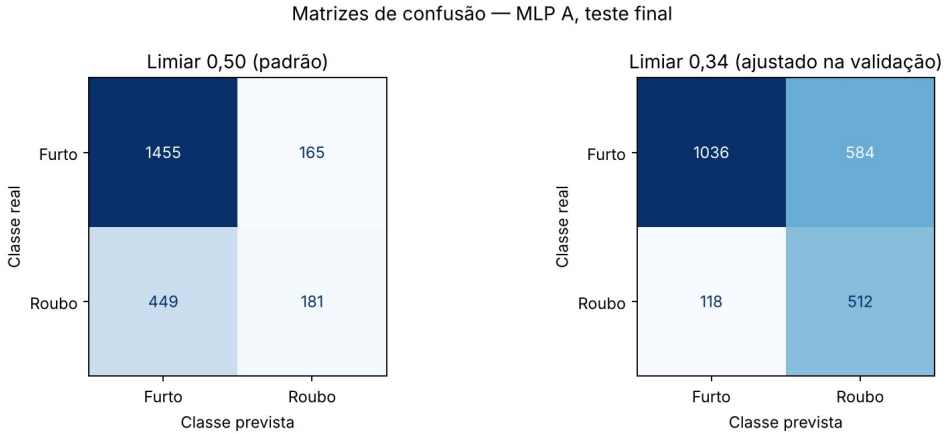
Por que ajustar o limiar

Roubo é só 28% dos casos, então a rede raramente passa de 0,5 e deixa muitos roubos escaparem. Com limiares de 0,05 a 0,60 testados só na validação, o F1 das três sobe para cerca de 59,5% (A: 0,34; B: 0,27; C: 0,32). Empate técnico: fica a rede mais simples, a A.

Curvas, matriz de confusão e análise

Rede A: treino e validação à esquerda, teste final (limiares 0,50 e 0,34) à direita





Overfitting: pouco

Na melhor época (9), a perda foi de 0,4774 no treino e 0,4920 na validação; a acurácia, de 74% e 72%. As curvas ficam próximas e o EarlyStopping interrompeu o treino.

Underfitting por falta de informação

A acurácia de validação (72,04%) fica perto de “sempre furto” (71,96%). Redes maiores não melhoraram a perda: faltam informações nos atributos.

Efeito do limiar 0,34 no teste

Recall de roubo de 28,7% para 81,3%; precision de 52,3% para 46,7%; acurácia de 72,7% para 68,8%. A rede acha 512 dos 630 roubos, com 584 alarmes falsos.

Aplicação web

Site estático: a MLP roda no navegador, sem servidor Python



1. **Formulário:** bairro, período, tipo de local e dia da semana: os quatro atributos do treino.
2. **Modelo:** o JavaScript aplica o one-hot e os pesos da MLP A lidos de modelo_web.json.
3. **Resposta:** classe estimada e probabilidades de furto e roubo (roubo se for 34% ou mais).
4. **Publicação:** pasta docs/ no GitHub Pages; o link da aplicação está no README.

Exemplo do enunciado: Pinheiros, sexta, noite, via pública resulta em furto 91,65% e roubo 8,35%; com período NAO INFORMADO, em roubo 44,70%. **Conferência:** 300 exemplos, JavaScript × Keras, mesmas classes e diferença máxima menor que 0,0000001.

Conclusões, limitações e uso de IA

Conclusões

- A MLP A com limiar 0,34 encontra 81,27% dos roubos no teste (F1 de 59,33%).
- A acurácia (68,80%) fica abaixo de “sempre furto” (72,00%): aqui recall e F1 dizem mais.
- As três redes empatam; o ganho veio de tratar o desbalanceamento, não de uma rede maior.

Limitações

- Período não informado (57%) está ligado a roubo: a rede aprende parte de como o boletim foi preenchido.
- Dia da semana quase não ajuda; só duas naturezas “- OUTROS”; uma única divisão dos dados.
- Demonstração acadêmica: não serve para decisões reais de segurança pública.

Uso de IA generativa

- Apoiou a escrita e a revisão do código do notebook e do site, da documentação e da análise.
- As decisões de modelagem estão justificadas no notebook; os números vêm da execução com os dados públicos.
- O site foi conferido contra o modelo Keras salvo em 300 exemplos.

A rede classifica um registro já feito. Ela não prevê se um crime vai acontecer.